



Atatürk Üniversitesi

Mühendislik Fakültesi — Yazılım Mühendisliği
Örüntü Tanıma — Proje Ödevi

MRI Görüntülerinden Beyin Tümörü Tespiti ve Sınıflandırılması için Derin Öğrenme Tabanlı Bir Sistem

Ad Soyad: Sefer Mavi

Haziran 2026

Özet

Bu çalışmada, Manyetik Rezonans Görüntüleme (MRI) verileri kullanılarak beyin tümörlerinin otomatik tespiti ve sınıflandırılması için derin öğrenme tabanlı iki aşamalı bir sistem geliştirilmiştir. İlk aşamada bireyde tümör bulunup bulunmadığı belirlenmiş, ikinci aşamada ise tümör tipi Glioma, Meningioma ve Pituitary kategorilerine ayrılmıştır. Transfer öğrenme yaklaşımıyla MobileNetV2, EfficientNetB0 ve ResNet50 mimarileri karşılaştırılmış; her model önce dondurulmuş tabanla hızlıca eğitilmiş, en başarılı model ince ayar (fine-tuning) ile yeniden eğitilmiştir. En yüksek başarımları %92,62 test doğruluğu ile ince ayarlı ResNet50 modeli vermiştir. Tümör tespiti aşamasında ise %97,56 doğruluk, %96,75 duyarlılık ve %100 özgüllük elde edilmiştir. Sonuçlar, transfer öğrenme ve ince ayarın MRI temelli beyin tümörü analizinde yüksek başarımlı ve klinik karar desteğine uygun bir çözüm sunabileceğini göstermektedir.


1. Giriş

Beyin tümörleri, erken teşhis edilmediğinde yüksek ölüm oranına sahip ciddi hastalıklardır. Manyetik Rezonans Görüntüleme (MRI), yumuşak doku ayırımındaki üstünlüğü sayesinde beyin tümörlerinin tanısında yaygın olarak kullanılan, radyasyon içermeyen bir görüntüleme yöntemidir. Ancak MRI görüntülerinin uzman radyologlar tarafından değerlendirilmesi zaman alıcıdır ve gözlemciler arası değişkenliğe açıktır. Bu nedenle, bilgisayar destekli otomatik analiz sistemleri hem teşhis sürecini hızlandırmak hem de tutarlılığı artırmak açısından önem taşımaktadır.

Bu projenin amacı, MRI görüntülerinden beyin tümörünün otomatik tespitini ve tipinin sınıflandırılmasını yüksek doğrulukla gerçekleştiren bir görüntü tanıma sistemi geliştirmektir. Çalışma iki aşamalı olarak kurgulanmıştır: birinci aşamada tümör varlığı (var/yok) tespit edilmekte, ikinci aşamada ise tümör tipi (Glioma, Meningioma, Pituitary) belirlenmektedir. Sistemin geliştirilmesinde, sınırlı eğitim süresi içinde yüksek başarımla hedefiyle transfer öğrenme yaklaşımı benimsenmiş ve birden fazla derin öğrenme mimarisi karşılaştırılmıştır.

2. Veri Seti

Çalışmada Kaggle üzerinde yayımlanan ve etiketli MRI görüntülerinden oluşan Brain Tumor MRI Dataset kullanılmıştır. Veri seti dört sınıf içermektedir: glioma, meningioma, pituitary (üç tümör tipi) ve notumor (sağlıklı / tümörsüz). Görüntüler, eğitim ve test olmak üzere iki ana klasöre ayrılmış olarak sağlanmaktadır. Eğitim verisinin %20'si, modelin eğitim sırasında izlenmesi için doğrulama (validation) kümesi olarak ayrılmıştır. Bu çalışmada kullanılan eğitim kümesi her sınıftan 1400 görüntü olmak üzere toplam 5600 dengeli görüntüden, test kümesi ise her sınıftan 400 görüntü olmak üzere toplam 1600 dengeli görüntüden oluşmaktadır. Eğitim kümesindeki sınıf dağılımı Şekil 1'de gösterilmiştir.




Şekil 1. Eğitim kümesindeki sınıf dağılımı (her sınıfta 1400, toplam 5600 görüntü).

Tablo 1. Test kümesinin sınıflara göre dağılımı.

Sınıf	Açıklama	Test Görüntü Sayısı
glioma	Glioma tümörü	400
meningioma	Meningioma tümörü	400

Sınıf	Açıklama	Test Görüntü Sayısı
notumor	Tümör yok (sağlıklı)	400
pituitary	Pituitary (hipofiz) tümörü	400
Toplam	—	1600

Her bir tümör tipinin ve sağlıklı (notumor) sınıfının MRI görüntülerindeki tipik görünümü Şekil 2'de örneklenmiştir. Görüntülerin farklı kesit düzlemlerinde (aksiyel, sagittal) ve farklı yoğunluk dağılımlarında olması, veri setinin çeşitliliğini yansıtmaktadır.



Şekil 2. Her sınıftan örnek MRI görüntüleri.

3. Yöntem

3.1. Ön İşleme

Tüm görüntüler, kullanılan önceden eğitilmiş mimarilerin giriş gereksinimine uygun olarak 224×224 piksel boyutuna ölçeklendirilmiştir. Normalizasyon, her mimarinin kendi preprocess_input fonksiyonu aracılığıyla mimariye özgü biçimde uygulanmıştır. Eğitim verisinin çeşitliliğini artırmak ve aşırı öğrenmeyi (overfitting) azaltmak için veri artırma (data augmentation) teknikleri kullanılmıştır: yatay çevirme, döndürme, yakınlaştırma, kontrast değişimi ve kaydırma. Bu dönüşümler yalnızca eğitim sırasında uygulanmış, doğrulama ve test aşamalarında devre dışı bırakılmıştır. Ek olarak, MRI görüntülerindeki gürültüyü azaltmak için isteğe bağlı bir Gaussian bulanıklaştırma adımı tanımlanmış; eğitimi yavaşlatmamak için varsayılan olarak kapalı tutulmuştur.

3.2. Özellik Çıkarımı ve Transfer Öğrenme

Özellik çıkarımında transfer öğrenme yaklaşımı benimsenmiştir. ImageNet veri seti üzerinde önceden eğitilmiş evrişimli sinir ağları (CNN) taban ağ olarak kullanılmış; bu ağların öğrendiği genel görsel özellikler, MRI görüntülerinin temsil edilmesinde değerlendirilmiştir. Taban ağın çıkışına Global Average Pooling katmanı eklenerek özellik vektörü elde edilmiş, ardından aşırı öğrenmeyi azaltmak için Dropout (0,4) ve son olarak dört sınıflı softmax sınıflandırıcı katmanı yerleştirilmiştir.

3.3. Kullanılan Modeller

Karşılaştırma amacıyla üç farklı CNN mimarisi kullanılmıştır:

- MobileNetV2 — hafif ve hızlı, sınırlı kaynaklı ortamlar için uygun bir mimari.
- EfficientNetB0 — bileşik ölçekleme ile verimlilik ve doğruluğu dengeleyen bir mimari.

- ResNet50 — artık bağlantılar sayesinde derin ağların etkin eğitilmesini sağlayan güçlü bir mimari.

3.4. Eğitim Stratejisi

Eğitim, hız ve doğruluğu dengelemek üzere iki aşamalı olarak tasarlanmıştır. Birinci aşamada (dondurulmuş eğitim), taban ağın ağırlıkları sabit tutulmuş ve yalnızca üstteki sınıflandırıcı katmanları eğitilmiştir; bu aşama oldukça hızlıdır. İkinci aşamada (ince ayar / fine-tuning), taban ağın üst katmanları çözülerek çok düşük bir öğrenme oranıyla ($1e-5$) yeniden eğitilmiş, böylece modelin MRI verisine özgü desenleri öğrenmesi sağlanmıştır. Hesaplama maliyetini azaltmak için pahalı olan ince ayar adımı yalnızca dondurulmuş aşamada en yüksek doğrulama başarımını veren modele uygulanmıştır.

Eğitim sırasında sınıflar arası olası dengesizliği gidermek için sınıf ağırlıklandırması (class weighting) kullanılmıştır. Aşırı öğrenmeyi engellemek ve eğitimi hızlandırmak amacıyla erken durdurma (EarlyStopping) ve öğrenme oranını uyarlamalı düşürme (ReduceLROnPlateau) geri-çağrılarını uygulanmıştır.


3.5. Değerlendirme Metrikleri

Modeller; doğruluk (accuracy), kesinlik (precision), duyarlılık (recall), F1-skoru ve ROC eğrisi altındaki alan (AUC) metrikleriyle değerlendirilmiştir. Sınıflandırma performansı ayrıca karışıklık matrisi (confusion matrix) ile incelenmiştir. Tümör tespiti aşamasında, klinik açıdan kritik olduğu için özellikle duyarlılık (tümörü kaçırmama oranı) ve özgüllük (sağlıklı kişiyi yanlış işaretlememe oranı) öne çıkarılmıştır.

4. Bulgular

4.1. Eğitim Süreci

Üç modelin doğrulama doğruluğu ve kaybı eğitim boyunca izlenmiştir (Şekil 3). Grafiklerdeki kesikli dikey çizgi, ince ayar (fine-tuning) aşamasının başladığı noktayı göstermektedir. ResNet50 modelinde ince ayar sonrasında doğrulama doğruluğunun belirgin biçimde yükseldiği, kaybın ise düştüğü görülmektedir. Bu durum, ince ayarın model başarımına katkısını açıkça ortaya koymaktadır.




Şekil 3. Modellerin doğrulama doğruluğu (sol) ve kaybı (sağ) eğrileri. Kesikli çizgi ince ayarın başlangıcını gösterir.

4.2. Model Karşılaştırması

Modellerin test kümesi üzerindeki doğruluk değerleri Tablo 2 ve Şekil 4'te sunulmuştur. İnce ayar yalnızca en başarılı dondurulmuş modele (ResNet50) uygulandığından, ResNet50 diğer iki modele kıyasla belirgin biçimde daha yüksek doğruluk elde etmiştir.

Tablo 2. Modellerin test kümesi doğruluk karşılaştırması.

Model	Eğitim Türü	Test Doğruluğu
EfficientNetB0	Dondurulmuş	%84,9
MobileNetV2	Dondurulmuş	%85,1
ResNet50	Dondurulmuş + İnce Ayar	%92,62




Şekil 4. Modellerin test doğruluğu karşılaştırması.

4.3. Sınıflandırma Performansı

En başarılı model olan ResNet50'nin sınıf bazındaki performansı Tablo 3'te, karışıklık matrisi ise Şekil 5'te verilmiştir. notumor ve pituitary sınıfları neredeyse kusursuz tanınmıştır. En düşük duyarlılık glioma sınıfında (0,782) gözlenmiştir; karışıklık matrisinden glioma örneklerinin önemli bir kısmının (52 örnek) meningioma olarak sınıflandırıldığı görülmektedir.

Tablo 3. ResNet50 için sınıf bazında sınıflandırma metrikleri.

Sınıf	Kesinlik	Duyarlılık	F1-Skoru	Destek
glioma	0,981	0,782	0,871	400
meningioma	0,870	0,938	0,902	400
notumor	0,911	1,000	0,953	400
pituitary	0,959	0,985	0,972	400
Doğruluk			0,926	1600
Makro Ort.	0,930	0,926	0,925	1600
Ağırlıklı Ort.	0,930	0,926	0,925	1600




Şekil 5. ResNet50 modelinin dört sınıflı karışıklık matrisi.

4.4. ROC Analizi

Her sınıf için bire-karşı-hepsi (one-vs-rest) yaklaşımıyla hesaplanan ROC eğrileri ve AUC değerleri Şekil 6 ve Tablo 4'te sunulmuştur. Tüm sınıflarda AUC değerleri 0,94'ün üzerinde olup; notumor ve pituitary sınıflarında 0,99'un üzerine çıkmıştır. Bu, modelin sınıfları ayırt etme gücünün yüksek olduğunu göstermektedir.

Tablo 4. Sınıf bazında ROC AUC değerleri (ResNet50).

Sınıf	AUC
glioma	0,949
meningioma	0,986
notumor	0,998
pituitary	0,999




Şekil 6. ResNet50 modelinin sınıf bazında ROC eğrileri.

4.5. Aşama 1 — Tümör Tespiti

Projenin birinci aşaması olan tümör tespiti için, dört sınıflı modelin tahminleri 'tümör var' (glioma, meningioma, pituitary) ve 'tümör yok' (notumor) olmak üzere ikili biçimde birleştirilmiştir. Elde edilen sonuçlar Tablo 5 ve Şekil 7'de verilmiştir. Model, sağlıklı görüntülerin tamamını doğru sınıflandırarak %100 özgüllük elde etmiştir; yani hiçbir sağlıklı kişiye yanlışlıkla tümör tanısı konmamıştır. 1200 tümörlü görüntünün 1161'i doğru tespit edilmiş, 39'u ise gözden kaçırılmıştır (%96,75 duyarlılık).

Tablo 5. Tümör tespiti (ikili) performans metrikleri ve karışıklık matrisi sayıları.


Metrik / Hücre	Değer
Doğruluk (Accuracy)	%97,56
Duyarlılık (Sensitivity)	%96,75
Özgüllük (Specificity)	%100,00
Doğru Negatif (Tümör Yok → Yok)	400
Yanlış Pozitif (Tümör Yok → Var)	0
Yanlış Negatif (Tümör Var → Yok)	39
Doğru Pozitif (Tümör Var → Var)	1161



Şekil 7. Tümör tespiti (ikili) karışıklık matrisi.

4.6. Örnek Tahminler

Modelin örnek test görüntüleri üzerindeki tahminleri Şekil 8'de sunulmuştur. Üst satır görüntülerin gerçek etiketini, alt satır ise modelin verdiği tahmini göstermektedir. Seçilen glioma örneklerinin bir kısmı doğru sınıflandırılırken, bir kısmı notumor veya meningioma olarak hatalı sınıflandırılmıştır. Bu durum, glioma sınıfının diğer kategorilerle (özellikle meningioma ile) karışabildiğini somut olarak göstermekte ve Bölüm 5'te tartışılan bulgularla örtüşmektedir.



Şekil 8. Test kümesinden örnek tahminler (üst satır: gerçek etiket, alt satır: model tahmini).

5. Tartışma

Elde edilen bulgular, transfer öğrenme ve ince ayarın MRI temelli beyin tümörü analizinde etkili olduğunu göstermektedir. Dondurulmuş eğitimle yaklaşık %84 düzeyinde kalan ResNet50 modeli, ince ayar sonrasında %92,62 test doğruluğuna ulaşmıştır. Bu artış, taban ağın üst katmanlarının MRI verisine uyarlanmasıyla önemini vurgulamaktadır.

Sistemin en güçlü yönü tümör tespiti aşamasıdır. %100 özgüllük, sağlıklı bireylerde gereksiz alarm üretilmediğini; %96,75 duyarlılık ise tümörlerin büyük çoğunluğunun yakalandığını göstermektedir. Klinik açıdan en kritik hata tipi, var olan bir tümörün gözden kaçırılmasıdır (yanlış negatif). Bu çalışmada 39 tümörlü görüntü 'tümör yok' olarak sınıflandırılmıştır; gerçek bir klinik uygulamada bu oranın daha da düşürülmesi hedeflenmelidir.

Çalışmanın bazı sınırlılıkları bulunmaktadır. Model tek bir veri seti üzerinde değerlendirilmiştir; farklı cihaz ve protokollerle elde edilmiş dış veri kümeleri üzerinde test edilmesi, genelleme yeteneğini daha sağlıklı ortaya koyacaktır. Şekil 8'deki örnek tahminler, model hatalarının büyük ölçüde glioma sınıfında yoğunlaştığını görsel olarak da desteklemektedir.

6. Sonuç

Bu projede, MRI görüntülerinden beyin tümörünü tespit eden ve tipini sınıflandıran iki aşamalı, derin öğrenme tabanlı bir sistem geliştirilmiştir. Transfer öğrenme ile üç farklı mimari karşılaştırılmış, en başarılı model olan ResNet50'ye ince ayar uygulanarak %92,62 sınıflandırma doğruluğu elde edilmiştir. Tümör tespiti aşamasında ise %97,56 doğruluk ile yüksek başarımlı sonuçlar alınmıştır.

Kaynaklar

- [1] Nickparvar, M. Brain Tumor MRI Dataset. Kaggle.
<https://www.kaggle.com/datasets/masoudnickparvar/brain-tumor-mri-dataset>
- [2] Örüntü Tanıma ders içerikleri.